Đánh giá Kronos mini, small và base trên chuỗi thời gian VN30

Zero-shot, supervised fine-tuning và các đối chứng thống kê

Vi Nguyễn Ngọc Châu **Nguyễn Hoàng Kiên**

Nhóm 1nsider

Kronos-VN30-Time-series-Forecasting

Tóm tắt

Báo cáo khảo sát khả năng ứng dụng các pre-trained model vào prediction Open/Close của chỉ số VN30, với trọng tâm là Kronos-mini, Kronos-small và Kronos-base. Trên snapshot gồm 2.271 phiên, nghiên cứu sử dụng context 128 session, prediction horizon 20 session và đánh giá tại $h = 1, 5, 20$. Thiết kế kết hợp zero-shot, supervised fine-tuning (SFT), bốn baseline, đối chứng Chronos-2-small, ba seed, learning curve, quantize ablation và hai expanding-window fold. SFT cải thiện rõ Kronos-base ở Close $h = 20$: MAE giảm từ 166,781 xuống 98,849 điểm, tương đương 40,7% so với zero-shot. Mini SFT có chi phí thấp và đạt sai số thấp hơn small SFT ở cả ba horizon. Tuy vậy, Naive vẫn có MAE Close thấp nhất trong bảng chính; lợi ích của pre-training và quantize phụ thuộc model, horizon và điều kiện thực nghiệm. Các kết quả cho thấy giá trị của việc đánh giá foundation model cùng baseline đơn giản và các đối chứng có kiểm soát trên cùng forecast origins.

Từ khóa: VN30; Kronos; time-series foundation model; pre-trained model; SFT; tokenization; quantize; forecasting.

1 Đặt vấn đề

Time-series foundation model chuyển một phần chi phí học biểu diễn sang giai đoạn pre-training, sau đó thực hiện inference trên các chuỗi mới hoặc SFT với dữ liệu của bài toán đích. Trong tài chính, dữ liệu nến chứa quan hệ đồng thời giữa Open, High, Low và Close, nên cách biểu diễn input cũng là một thành phần cần đánh giá. Kronos tiếp cận bài toán bằng tokenization dữ liệu K-line và một predictor autoregressive [7]. Chronos-2 cung cấp một hướng đối chứng tổng quát cho chuỗi thời gian với quantile predictions [2].

VN30 được chọn làm trường hợp nghiên cứu cho prediction mức giá chỉ số theo session. Báo cáo không mặc định rằng model lớn hơn hoặc SFT sẽ tốt hơn. Bốn câu hỏi nghiên cứu được xác định như sau:

1. **Q1:** Kronos và Chronos có MAE thấp hơn Naive, Ridge, ARIMA và ETS trên cùng input và target không?
2. **Q2:** Model size và bước quantize đóng góp thế nào vào kết quả?
3. **Q3:** Data budget và predictor pre-training ảnh hưởng ra sao?
4. **Q4:** Kết quả có ổn định khi đổi seed, horizon và giai đoạn test không?

Đóng góp chính của thiết kế là kết hợp so sánh nhiều model với kiểm soát split, checkpoint selection và forecast-origin coverage; đồng thời bổ sung ablation, random initialization và evaluation theo thời gian.

2 Mô hình và phương pháp

2.1 Kronos: tokenization và autoregressive predictor

Kronos sử dụng tokenizer gồm encoder, quantize và decoder. Encoder đưa numeric input thành continuous features; Binary Spherical Quantization (BSQ) chuyển features thành token IDs; predictor dùng token quá

khứ để predict token tiếp theo; decoder khôi phục OHLC. Vì vậy, *tokenization* là toàn bộ quá trình tạo token, còn *quantize* là một bước trong quá trình đó. Predictor sử dụng causal Transformer và cấu trúc output phân cấp. Trong SFT, weight của predictor được cập nhật, tokenizer giữ cố định.

Bảng 1. Các neural model trong thực nghiệm. M là triệu tham số.

Model	Tham số (M)	Tokenizer / vai trò
Kronos-mini	4,1	Kronos-Tokenizer-2k
Kronos-small	24,7	Kronos-Tokenizer-base
Kronos-base	102,3	Kronos-Tokenizer-base
Chronos-2-small	27,9	Model chuỗi thời gian tổng quát, quantile output

Kronos-mini khác tokenizer của small/base, nên so sánh ba model phản ánh khác biệt giữa các hệ thống hoàn chỉnh, chưa tách riêng tác động của số tham số. Chronos-2-small là checkpoint 28M trong họ Chronos-2 [3]. Mỗi neural model có zero-shot và SFT; zero-shot dùng weight pre-trained, SFT train thêm trên train split VN30.

2.2 Baseline

Các baseline cung cấp chuẩn so sánh có cấu trúc khác nhau [5]. Naive không train, dùng Close tại forecast origin t cho cả Open và Close tại các target:

$$\widehat{O}_{t+h} = \widehat{C}_{t+h} = C_t, \qquad h = 1, \ldots, 20. \tag{1}$$

Ridge fit ánh xạ tuyến tính từ 128 session OHLC tới toàn bộ path tương lai, với regularization để hạn chế weight quá lớn [4]. Input và target scaler chỉ fit trên train.

ARIMA kết hợp quan hệ với lag của chuỗi, differencing và error quá khứ. ETS sử dụng exponential smoothing, xét level và các cấu hình trend. Hai phương pháp fit lại từng kênh trên 128 session tại mỗi forecast origin, không sử dụng seasonal component. Cấu hình được chọn trên validation: Ridge $\alpha = 10$, ARIMA $(0, 1, 0)$ và ETS level. Lưới tương ứng gồm 4, 18 và 3 ứng viên. Các fit lỗi hoặc thiếu coverage được ghi nhận và không được chọn, không thay forecast lỗi bằng Naive.

ARIMA $(0, 1, 0)$ và ETS level được chọn cho Close prediction trùng Naive trong thực nghiệm này. Điều đó không biến ba nhãn model thành ba bằng chứng độc lập. Open prediction vẫn có thể khác vì ARIMA/ETS fit Open riêng, trong khi Naive dùng Close cho cả hai target.

3 Dữ liệu và protocol đánh giá

3.1 Snapshot và split theo thời gian

Snapshot VNDIRECT gồm 2.271 session từ 24/08/2017 đến 01/10/2026, đơn vị điểm chỉ số. Dữ liệu OHLC được giữ nguyên, không nội suy session và không ghép giá từ nhiều nguồn theo từng ô. Các bước pre-process gồm kiểm hash, SQLite integrity, raw replay, timestamp, duplicate, giá không hữu hạn, quan hệ OHLC và đối chiếu nguồn.

Bảng 2. Ranh giới thời gian và số forecast origins hợp lệ.

Split	Từ ngày	Đến ngày	Session	Origins
Train	24/08/2017	29/12/2023	1.589	1.442
Validation	02/01/2024	20/05/2025	340	321
Test	21/05/2025	01/10/2026	342	323

Session là một phiên giao dịch, tương ứng một dòng OHLC. *Forecast origin* là thời điểm chốt input

sau khi có Close của session t. Từ đó, model predict 20 target session. Test có 342 session nhưng chỉ có $342 - 20 + 1 = 323$ origins chứa đủ 20 target trong test. Context 128 session được phép lấy từ quá khứ trước ranh giới test. Train có $1589 - 128 - 20 + 1 = 1442$ windows vì cả input và target phải nằm trong train split.

Các chênh lệch OHLC giữa nhà cung cấp chưa được phân xử đầy đủ, nên giá trong snapshot chưa được xác nhận toàn bộ với nguồn công bố chính thức. Đặc biệt, đoạn 05/05–11/08/2025 có 71 session liên tiếp Open bằng Close trước; ảnh hưởng lên Open MAE được phân tích riêng ở Mục 4.2. Các phép so sánh dưới đây được hiểu theo nhãn của snapshot đang đánh giá.

3.2 Inference và metric

Mọi model trong một bảng dùng cùng forecast origins. Context là 128 session, path dài 20 session, chấm Open/Close tại tập horizon $\mathcal{H} = \{1, 5, 20\}$. Toàn bộ 20 target của một window nằm trong split tương ứng. Các cấu hình được khóa bằng validation trước khi chấm test; prediction được lưu trước khi ghép label để tính metric.

Kronos sample ba paths với temperature 1 và top-$p = 0,9$, lấy mean tại từng target session. Chronos lấy mean của 13 quantile outputs tại từng session. Hai quy tắc tổng hợp được giữ nhất quán giữa zero-shot và SFT; quantile không phải sampled path, và mean quantile không được gọi là median hay kỳ vọng chính xác. Volume/amount thiếu được adapter điền 0; đây là quy ước input, không phải khối lượng giao dịch thực.

Với n forecast origins và target y_{t_i+h}, các metric là:

$$\mathrm{MAE}_h = \frac{1}{n}\sum_{i=1}^{n} |\widehat{y}_{t_i+h} - y_{t_i+h}|, \tag{2}$$

$$\mathrm{RMSE}_h = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (\widehat{y}_{t_i+h} - y_{t_i+h})^2}. \tag{3}$$

MAE là metric chính; RMSE bổ sung thông tin về error lớn. Cả hai có đơn vị điểm chỉ số. Mean $\pm$ SD được tính qua seed 42, 43 và 44; SD giữa seed không thay thế confidence interval theo thời gian.

3.3 SFT và checkpoint selection

SFT dùng FP32, AdamW, learning rate 10^{-6}, effective batch 16, gradient clipping $1,0$ và tối đa năm epoch. Microbatch 8, gradient accumulation 2 giữ batch hiệu dụng cố định. Khoảng 1.442 windows tạo 91 optimizer updates/epoch, tức 455 updates cho năm epoch.

Hai lựa chọn được lưu riêng: *best-trained* là checkpoint có validation loss tốt nhất sau cập nhật; *selected* cho phép chọn cả epoch 0, tức weight pre-trained trước SFT. Các hàng mang nhãn SFT trong bảng metric dùng best-trained để đo tác động cập nhật.

Bảng 3. Epoch được chọn; mỗi model có cùng kết quả lựa chọn ở ba seed.

Model	Best-trained epoch	Selected epoch	Seed
Kronos-mini	5	5	42/43/44
Kronos-small	5	5	42/43/44
Kronos-base	5	5	42/43/44
Chronos-2-small	1	0	42/43/44

Ba Kronos chọn epoch 5 trong khoảng đã thử. Đây là kết quả dưới budget năm epoch, chưa chứng minh đã hội tụ hoặc tìm được epoch tối ưu. Chronos chọn epoch 0 theo native validation ở cả ba seed; vì vậy selected Chronos là bản pre-trained, còn hàng Chronos SFT phía sau là best-trained epoch 1. Không so trực tiếp token cross-entropy của Kronos với quantile loss của Chronos.

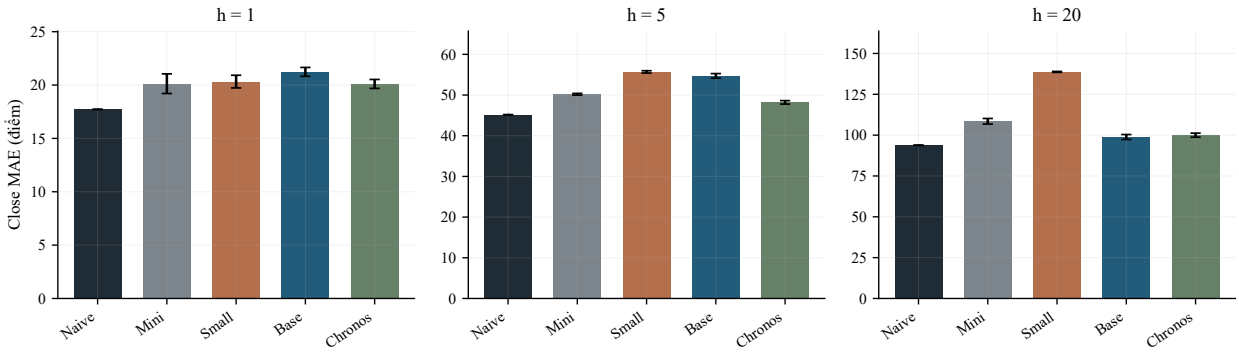
4 Kết quả thực nghiệm

4.1 Q1: So sánh với baseline

Bảng 4 trình bày Close MAE cho toàn bộ model. Naive đạt 17,722 / 45,165 / 93,826 điểm tại $h = 1/5/20$, thấp hơn mean của các neural model trong bảng chính. Ridge ở giữa các hệ thống tại một số horizon, còn Close của ARIMA/ETS trùng Naive như đã giải thích.

Bảng 4. Close MAE trên test, mean ± SD ba seed. Model deterministic không ghi SD bằng 0; forecast dùng chung không được xem là ba ước lượng độc lập. SFT là best-trained.

Model	$h = 1$	$h = 5$	$h = 20$
Naive	**17,722**	**45,165**	**93,826**
Ridge	21,597	49,598	105,211
ARIMA	17,722	45,165	93,826
ETS	17,722	45,165	93,826
Kronos-mini	20,587 ± 0,382	53,345 ± 0,859	121,571 ± 0,845
Kronos-mini SFT	20,127 ± 0,920	50,188 ± 0,219	108,490 ± 1,706
Kronos-small	19,906 ± 0,566	52,586 ± 0,327	154,143 ± 1,136
Kronos-small SFT	20,326 ± 0,594	55,690 ± 0,285	138,716 ± 0,279
Kronos-base	20,889 ± 0,132	55,148 ± 0,574	166,781 ± 0,712
Kronos-base SFT	21,234 ± 0,417	54,709 ± 0,562	98,849 ± 1,525
Chronos-2-small	19,995	47,699	102,072
Chronos-2-small SFT	20,104 ± 0,421	48,198 ± 0,428	99,976 ± 1,244



Hình 1. Close MAE của Naive và bốn neural model SFT. Error bar là SD giữa seed, không phải confidence interval.

Trong các Kronos SFT, base có Close $h = 20$ MAE thấp nhất ở 98,849 điểm; mini đạt 108,490 và small đạt 138,716. Ở $h = 1/5$, mini có mean MAE thấp hơn small và base. Chronos best-trained SFT đạt 99,976 điểm tại $h = 20$. Các kết quả này cho thấy thứ hạng phụ thuộc horizon; chưa có ưu thế tổng thể của neural model trước Naive trong protocol đã thử.

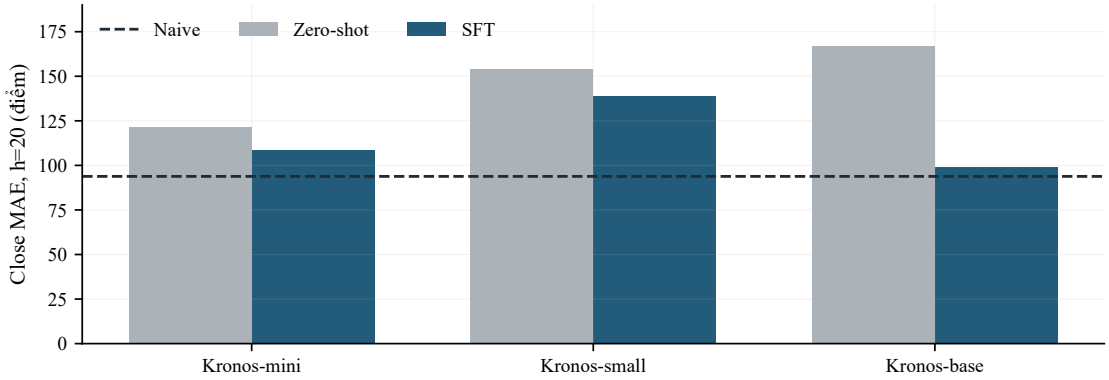
4.2 Open và đặc điểm của label

Open h=1 MAE của Naive là 5,959 điểm, thấp hơn các neural model. Một phần kết quả liên quan tới cấu trúc label: trong 323 test origins, có 59 origins mà target thuộc đoạn Open bằng Close trước. Vì Naive predict bằng Close tại origin, error trên nhóm này bằng 0; trên 264 origins còn lại, Open MAE của Naive là 7,291.

Ví dụ dữ liệu thật: Close ngày 20/05/2025 là 1.407,52; Open ngày 21/05/2025 cũng bằng 1.407,52; Naive predict Open là 1.407,52, nên absolute error bằng 0. Không có rule riêng cho nhóm 59 origins và không sử dụng target tương lai. Do đó, Open MAE cần được đọc cùng định nghĩa và cách dựng nhãn của nguồn, chưa thể đồng nhất với khả năng predict giá mở cửa chính thức. Bảng Open đầy đủ ở Phụ lục A.1.

4.3 Q2: Model size và tác động SFT

SFT tạo cải thiện rõ cho Kronos-base ở horizon dài: Close $h = 20$ MAE giảm 67,932 điểm, từ 166,781 xuống 98,849, tương đương 40,7% so với zero-shot (Hình 2). Mini và small cũng giảm Close $h = 20$ MAE sau SFT, nhưng mức cải thiện không đồng đều ở các horizon. Riêng base tại $h = 1$, MAE tăng nhẹ từ 20,889 lên 21,234, nên không diễn giải SFT như cải thiện mọi target và horizon.



Hình 2. Zero-shot và best-trained SFT của ba Kronos tại Close $h = 20$. Đường đứt là Naive, giúp đặt mức cải thiện SFT trong cùng thang so sánh.

Mini SFT có MAE thấp hơn small SFT ở cả ba horizon, đồng thời có chi phí thấp hơn. Sự khác biệt tokenizer ngăn việc quy toàn bộ khác biệt này cho số tham số. Bảng 5 bổ sung chi phí của từng hệ thống.

Bảng 5. Chi phí SFT, mean ba seed trên RTX 4070 SUPER 12 GB.

Model	Tham số (M)	SFT 5 epoch/seed (s)	Peak tensor (GiB)
Kronos-mini	4,1	20,5	0,198
Kronos-small	24,7	36,9	0,780
Kronos-base	102,3	87,4	2,543
Chronos-2-small	27,9	48,2	0,564

Thời gian trong bảng là **giai đoạn SFT năm epoch của một seed**, lấy mean qua ba seed. Timer bắt đầu sau setup model và, với Kronos, sau encode dữ liệu bằng tokenizer cố định; gồm initial validation, train, validation và lưu checkpoint, không gồm download/load/tokenize hay toàn bộ inference pipeline. Peak tensor memory là lượng bộ nhớ do PyTorch ghi nhận, khác tổng VRAM process. Thời gian ngắn phản ánh data budget nhỏ và teacher forcing, không chứng minh train đã đủ.

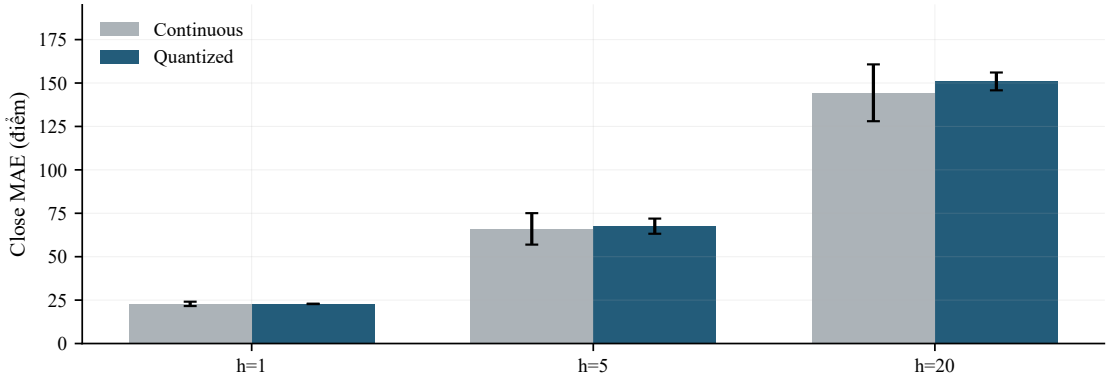
4.4 Q2: Quantize ablation

Ablation sử dụng cùng encoder tokenizer small cố định, cùng random small backbone, numeric head/MSE, data và train budget. Nhánh continuous dùng features L2-normalized trước BSQ; nhánh quantized dùng features sau BSQ. Initialization của predictor được ghép cặp theo seed.

Bảng 6. Quantize ablation: Close MAE, mean $\pm$ SD ba seed.

Representation	$h = 1$	$h = 5$	$h = 20$
Continuous	22,832 $\pm$ 1,255	66,015 $\pm$ 9,060	144,375 $\pm$ 16,360
Quantized	22,832 $\pm$ 0,134	67,571 $\pm$ 4,365	150,927 $\pm$ 5,131

Hai nhánh gần bằng nhau tại $h = 1$. Quantized có MAE mean cao hơn tại $h = 5/20$, trong khi SD giữa seed ở một số ô khá lớn. Chưa có bằng chứng quantize giúp Close MAE giảm đồng nhất trong ablation



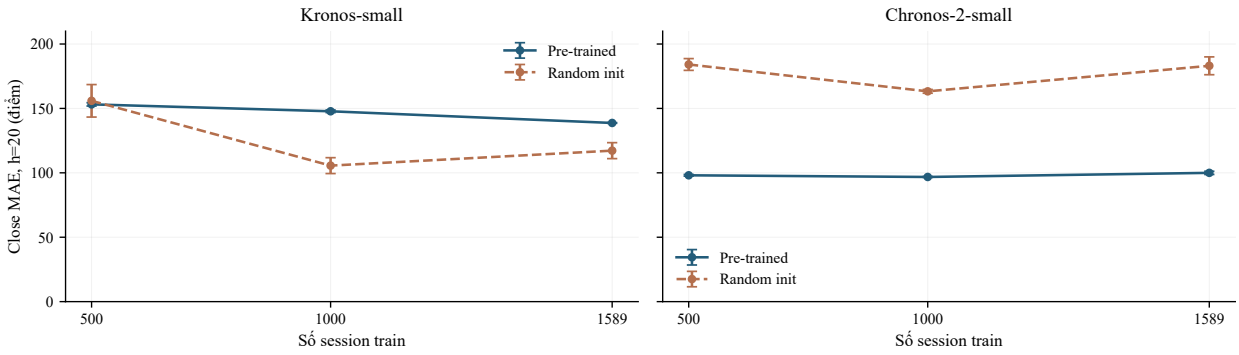
Hình 3. So representation trước/sau quantize trong ablation cố định. Error bar là SD giữa seed.

này. Kết luận chỉ áp dụng cho bước can thiệp đã thiết kế, không đánh giá riêng mọi thành phần của K-line representation hay toàn bộ hệ thống pre-trained.

4.5 Q3: Data budget và predictor pre-training

Kronos-small và Chronos-2-small được chọn cho learning curve với 500 / 1.000 / 1.589 session train, tương ứng 353 / 853 / 1.442 windows. Các đoạn train lồng nhau, cùng ngày kết thúc, giữ validation/test cố định. Pre-trained được so với predictor cùng kiến trúc khởi tạo ngẫu nhiên. Random Kronos vẫn sử dụng tokenizer pre-trained.

Mỗi trial tối đa năm epoch. Pre-trained giữ learning rate chính 10^{-6}; random chọn learning rate từ $\{10^{-6}, 10^{-5}, 10^{-4}\}$ bằng validation. Vì vậy, tổng search cost không bằng nhau dù budget của từng trial giống nhau. Hình 4 trình bày Close $h = 20$; ba horizon đầy đủ ở Phụ lục A.2.



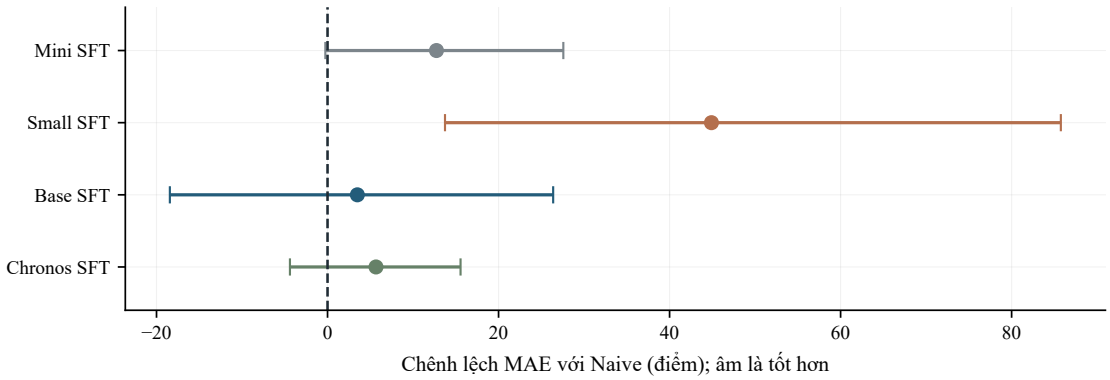
Hình 4. Learning curve tại Close $h = 20$. Error bar là SD ba seed. Pre-trained chỉ predictor bắt đầu từ weight đã học; random chỉ random initialization của predictor trong thiết lập tương ứng.

Chronos pre-trained có MAE thấp hơn random trong cả chín ô budget/horizon. Với Kronos-small, lợi ích không đồng nhất: tại 1.000 session, random tốt hơn pre-trained ở $h = 5/20$; full budget cũng có kết quả tương tự ở hai horizon này. Riêng Close $h = 20$ full, random đạt 117,220 so với pre-trained 138,716 điểm. Trong nhánh Kronos pre-trained, thêm data cải thiện $h = 20$ nhưng không làm mọi horizon cùng tốt hơn. Các kết luận giới hạn trong search space và training budget đã thử.

4.6 Q4: Seed, horizon và khoảng bất định

Để giữ cấu trúc phụ thuộc của các forecast origins chồng lấn, paired moving-block bootstrap được áp dụng cho chênh lệch absolute error với Naive, cùng origins, block dài 20 và 2.000 lần lấy mẫu [6]. CI percentile 95% dùng RNG seed 42. SD giữa ba training seed và bootstrap CI trả lời hai câu hỏi khác nhau; không ghép

ba seed thành các thị trường độc lập.



Hình 5. Chênh lệch Close $h = 20$ MAE với Naive, neural seed 42 và CI 95%. Âm nghĩa là tốt hơn Naive; CI cắt 0 chưa cho thấy khác biệt rõ trong phép kiểm này. Bảng ba horizon ở Phụ lục A.3.

Base SFT có chênh lệch $3,488$ điểm tại $h = 20$, CI $[-18,439;\ 26,387]$, còn small SFT có chênh lệch $44,896$ điểm với CI $[13,737;\ 85,757]$. CI chưa điều chỉnh multiple comparisons và còn phụ thuộc lựa chọn block. Các khoảng này giúp phân biệt chênh lệch số học với mức bất định, không chứng minh hai model tương đương khi cắt 0.

4.7 Q4: Giai đoạn và volatility

Volatility tại origin t là SD của 20 log-return đã quan sát:

$$r_t = \log(C_t/C_{t-1}), \qquad v_t = \mathrm{SD}(r_{t-19}, \ldots, r_t), \quad \mathrm{ddof} = 1. \tag{4}$$

Threshold p90 chỉ lấy từ train và giữ cố định cho test. Test có 17/323 origins vượt threshold, tạo hai cụm: 6 origins từ 11–18/03/2026 và 11 origins từ 20/03–03/04/2026. Rolling windows chồng lấn nên các origin trong một cụm không đại diện các biến cố độc lập.

Bảng 7. Close $h = 20$ MAE theo ba đoạn test và nhóm volatility cao, mean ba seed. Ba đoạn có 108/108/107 origins; high-volatility có 17 origins.

Model	Đoạn 1	Đoạn 2	Đoạn 3	High-vol.
Naive	109,977	98,685	72,618	159,355
Mini SFT	153,116	92,096	79,993	141,836
Small SFT	236,885	96,716	82,023	127,385
Base SFT	108,828	102,620	84,971	112,710
Chronos SFT	103,874	111,084	84,830	188,250

Base SFT có kết quả tốt hơn Naive trong đoạn 1 và nhóm high-volatility ở metric này, nhưng không giữ lợi thế ở mọi đoạn. Chronos SFT và Kronos-small SFT cũng có thứ hạng thay đổi theo giai đoạn. Do coverage của nhóm volatility cao còn ít, bảng được dùng để mô tả tính phụ thuộc điều kiện, chưa khẳng định độ bền qua nhiều đợt khủng hoảng.

4.8 Q4: Hai expanding-window fold

Mỗi fold gồm train/validation/test theo thời gian, với train mở rộng ở fold sau. Fold 1 kết thúc train ngày 11/03/2022, validation 14/03/2022–08/02/2023, test 09/02–29/12/2023. Fold 2 kết thúc train ngày 08/02/2023, validation 09/02–29/12/2023, test 02/01–28/11/2024. Mỗi fold có 208 test origins, neural seed 42, chọn checkpoint bằng validation riêng.

Chronos SFT nhỉnh hơn Naive tại fold 1 $h = 5$ (22,213 so với 22,363), nhưng không giữ lợi thế ở fold 2. Nhìn chung, chưa có neural model thắng nhất quán cả ba horizon và hai fold (Phụ lục A.4). Cả hai fold có 0 origins high-volatility theo threshold train riêng, nên chúng bổ sung kiểm tra theo thời gian nhưng chưa bổ sung bằng chứng về nhóm volatility cao.

5 Thảo luận

Kết quả cho thấy SFT có thể điều chỉnh một model pre-trained để phù hợp hơn với horizon của bài toán. Mức giảm MAE của base ở $h = 20$ là ví dụ rõ, đồng thời bảng toàn bộ horizon cho thấy cải thiện này không phổ quát. Mini mang lại cân bằng đáng chú ý giữa chi phí và error, còn baseline Naive giữ vai trò tham chiếu cần thiết khi predict mức giá chỉ số. Một MAE thấp cần được đặt trong cùng target, origins và cấu trúc label.

Ba điểm giới hạn cần giữ khi diễn giải là: nhãn OHLC còn khác biệt giữa nguồn; evaluation mang tính hồi cứu và chưa xác minh đầy đủ pre-training cutoff của từng revision; năm epoch và một số ít giai đoạn không đại diện tối ưu đến hội tụ hay mọi trạng thái thị trường. Đặc biệt, test lịch sử đã từng được xem trong nghiên cứu trước, nên không mô tả đây là một triển khai lịch sử hoàn toàn mới. Việc đánh giá tập trung vào MAE/RMSE mức giá, không suy trực tiếp thành lợi nhuận giao dịch hoặc kết quả sau chi phí.

6 Kết luận

Nghiên cứu cung cấp một đánh giá thống nhất cho Kronos mini/small/base, Chronos-2-small và bốn baseline trên VN30. Đối với Q1, neural model chưa thể hiện lợi thế ổn định trước Naive trong bảng chính. Đối với Q2, SFT cải thiện rõ base ở Close $h = 20$, trong khi model size và quantize chưa cho lợi ích đồng nhất. Đối với Q3, tác dụng predictor pre-training phụ thuộc model và data budget; thêm data chưa giúp mọi horizon. Đối với Q4, error và thứ hạng thay đổi theo thời gian, horizon và mức volatility.

Giá trị của kết quả nằm ở việc xác định điều kiện mà mỗi hệ thống hoạt động tốt hơn, cùng một protocol minh bạch để so sánh và tái lập, thay vì chỉ lựa chọn một model theo kích thước hoặc một điểm số đơn lẻ. Các bảng, code và phiên bản dữ liệu thực nghiệm được lưu trong kho dự án [1].

Tài liệu tham khảo

[1] 1nsider. Kronos-vn30-time-series-forecasting: dữ liệu thực nghiệm và kết quả tổng hợp. Mã nguồn và các bảng CSV theo phiên bản, 2026. URL https://github.com/HUSTlang-nguyen/Kronos-VN30-Time-series-Forecasting/tree/80f9d2b.

[2] Abdul Fatir Ansari, Oleksandr Shchur, Jaris Küken, et al. Chronos-2: From univariate to universal forecasting. arXiv:2510.15821, 2025. URL https://arxiv.org/abs/2510.15821.

[3] AutoGluon. Chronos-2-small: Model card. Hugging Face, n.d. URL https://huggingface.co/autogluon/chronos-2-small/tree/ddec01313e50b6bc58ebaa92ede81bc24a3d9f9a. Truy cập ngày 31/10/2026; revision được khóa trong URL.

[4] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970. doi: 10.1080/00401706.1970.10488634. URL https://doi.org/10.1080/00401706.1970.10488634.

[5] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, 3 edition, 2021. URL https://otexts.com/fpp3/.

[6] Hans R. Künsch. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 17 (3):1217–1241, 1989. doi: 10.1214/aos/1176347265. URL https://doi.org/10.1214/aos/1176347265.

[7] Yu Shi, Zongliang Fu, Shuo Chen, et al. Kronos: A foundation model for the language of financial markets. arXiv:2508.02739, 2025. URL https://arxiv.org/abs/2508.02739.

A Bảng kết quả bổ sung

A.1 Open MAE

Bảng 8. Open MAE trên test, mean ± SD ba seed; quy ước như Bảng 4.

Model	$h = 1$	$h = 5$	$h = 20$
Naive	**5,959**	**40,846**	**91,951**
Ridge	12,392	45,368	103,683
ARIMA	18,999	46,270	94,720
ETS	19,017	46,288	94,700
Kronos-mini	9,726 ± 0,111	49,886 ± 1,208	120,706 ± 0,866
Kronos-mini SFT	9,806 ± 0,100	46,878 ± 0,527	107,852 ± 1,582
Kronos-small	10,428 ± 0,206	48,808 ± 0,618	151,298 ± 1,071
Kronos-small SFT	10,208 ± 0,262	52,177 ± 0,445	131,519 ± 1,763
Kronos-base	10,408 ± 0,178	50,477 ± 0,377	164,544 ± 0,439
Kronos-base SFT	10,466 ± 0,313	49,770 ± 0,714	97,545 ± 1,373
Chronos-2-small	21,045	48,651	103,229
Chronos-2-small SFT	20,671 ± 0,555	48,740 ± 0,518	100,810 ± 1,251

A.2 Learning curve tại ba horizon

Bảng 9. Close MAE theo data budget và initialization, mean ba seed. Full budget là 1.589 session.

Model	Init.	Session	$h = 1$	$h = 5$	$h = 20$
Kronos-small	Pre-trained	500	20,067	50,523	153,161
Kronos-small	Pre-trained	1.000	20,325	53,489	147,780
Kronos-small	Pre-trained	1.589	20,326	55,690	138,716
Kronos-small	Random	500	32,188	86,797	155,908
Kronos-small	Random	1.000	21,925	52,265	105,597
Kronos-small	Random	1.589	21,743	54,729	117,220
Chronos-2-small	Pre-trained	500	19,753	47,364	98,074
Chronos-2-small	Pre-trained	1.000	19,498	47,449	96,782
Chronos-2-small	Pre-trained	1.589	20,104	48,198	99,976
Chronos-2-small	Random	500	152,647	160,078	184,120
Chronos-2-small	Random	1.000	129,054	140,272	163,259
Chronos-2-small	Random	1.589	149,456	157,607	183,093

A.3 Paired bootstrap intervals

Bảng 10. Chênh lệch Close MAE với Naive và CI 95%, seed 42, $n = 323$. Block 20 origins, 2.000 lần lấy mẫu.

Model	h	ΔMAE	CI 95%
Mini SFT	1	1,657	[0,369; 2,820]
Mini SFT	5	4,779	[1,732; 8,373]
Mini SFT	20	12,738	[-0,257; 27,575]
Small SFT	1	1,923	[-0,435; 4,147]
Small SFT	5	10,443	[1,700; 22,576]
Small SFT	20	44,896	[13,737; 85,757]
Base SFT	1	3,031	[0,899; 5,149]
Base SFT	5	9,236	[1,284; 17,878]
Base SFT	20	3,488	[-18,439; 26,387]
Chronos SFT	1	1,935	[0,734; 3,010]
Chronos SFT	5	2,772	[-0,539; 5,990]
Chronos SFT	20	5,666	[-4,396; 15,555]

A.4 Kết quả hai fold

Bảng 11. Close MAE trên hai fold, neural seed 42, 208 origins/fold. SFT dùng best-trained; mỗi fold có train/validation riêng.

Fold	Model	$h = 1$	$h = 5$	$h = 20$
1	Naive	9,472	22,363	40,009
1	Kronos-mini	10,541	25,600	50,098
1	Kronos-mini SFT	10,474	23,655	49,682
1	Kronos-small	11,039	27,526	57,831
1	Kronos-small SFT	10,990	27,708	59,611
1	Kronos-base	10,683	26,395	66,885
1	Kronos-base SFT	11,524	25,392	56,358
1	Chronos-2-small	10,829	24,046	44,165
1	Chronos-2-small SFT	10,417	22,213	40,958
2	Naive	8,395	20,580	36,072
2	Kronos-mini	9,592	22,950	45,265
2	Kronos-mini SFT	9,779	22,362	41,484
2	Kronos-small	9,515	21,456	43,456
2	Kronos-small SFT	10,216	24,614	40,315
2	Kronos-base	9,965	21,526	53,029
2	Kronos-base SFT	10,087	26,404	42,151
2	Chronos-2-small	9,241	21,020	37,369
2	Chronos-2-small SFT	10,449	21,978	42,643

A.5 Phiên bản và khả năng tái lập

Dataset SHA256:

```
fee0bd8c240a9d2be4ef5c9d287eede6c5506b0358c25545e72de99709da4fd2
```

Manifest lưu revision model/tokenizer, split, seed, aggregation và checkpoint selection. Bảng/hình sinh từ CSV đã kiểm tra, không train hay inference lại. Snapshot giữ hàng ngoài request ở 01/10/2026 và không bổ sung dữ liệu trước 2017.